

Pencarian dan Penambangan Web

Pengantar Web Mining

Mulaab M
Prodi Teknik Informatika
Universitas Trunojoyo Madura
2026

- 1. Punya repositori Web mining
- Dengan github.com/yourusername/ppw
- 2. Webstatis :Isinya
- 1. Profile anda
 - Nama :
 - NPM
 - Email :
- 2. Pengantar web mining

- Membuat repositori github dengan nama repository : ppw
Github.com/<user>/ppw

- 1. Masuk jam 9.40 (terlambat dilarang masuk !!!)
- 2. Membawa laptop (tidak membawa laptop dilarang masuk)
- 3. Tidak hadir 20% D (maximal 3 pertemuan)
- 4. Github.com/your username/ppw

Pengantar

- Kuliah ini memperkenalkan konsep dasar dan teknologi dari web mining.

Topik terdiri

- Pengantar Web Mining
- Web Crawling
- Web Data Preprocessing
- Pembelajaran Terawasi (Supervised Learning)
- Pembelajaran Tak terawasi (Unsupervised Learning)
- Web Content Mining (text mining)
- Web Usage Mining
- Web structure Mining (graph mining)
- Deployment System

Tujuan

- Mahasiswa akan dapat memahami dan menggunakan konsep dasar dan teknologi web mining.
- Mahasiswa akan dapat melakukan penelitian sistem informasi dalam konteks web mining.

Web Mining

- Penambangan web adalah proses menemukan dan mengekstrak informasi dari **internet** menggunakan berbagai teknik penambangan data. Informasi ini dapat digunakan oleh perusahaan untuk pengambilan keputusan yang efektif.

Definisi


Penambangan web adalah penggunaan teknik penambangan data untuk secara otomatis menemukan dan mengekstrak informasi dari layanan web" (Etzioni, 1996; CACM 39).

Penambangan web bertujuan untuk menemukan pola-pola berguna atau pengetahuan dari struktur hiperlink web, isi halaman web, serta perilaku pengguna." (Bing Liu, 2007, *Web Data Mining*).

Tantangan pemrosesan data Web

- Web adalah pangkalan data yang sangat besar
- Datanya dalam format HTML, XML, text
- Tantangan pemrosesan data Web)
 - Web adalah sangat besar untuk dilakukan penambahan data
 - Web sangat komplek
 - Web sangat dinamis
 - Web bukan domain yang spesifik
 - Web adalah segalanya

Taxonomy Web Mining



Penambangan Isi Web (Content Mining)

- Proses mengekstrak informasi berguna dari dokumen-dokumen web.
- Fokus pada konten halaman web seperti:
 - **Teks (Text Mining)**->Artikel, deskripsi, komentar
 - Gambar (Image Mining) -> Foto, ilustrasi
 - Audio (Audio Mining)-> Rekaman Suara, Musik
 - Video (Video Mining)-> Streaming clip
 - Data terstruktur (tabel, daftar)-> **tabel deskripsi**

Aplikasi Text Mining

- Ekstraksi Informasi
- Topic modelling
- Peringkasan dokumen
- Klasifikasi dokumen (sentiment analysis, opinion mining)
- Pengelompokan dokumen (Sistem Rekomendasi)
- Ekstraksi kata kunci

Klasifikasi Dokumen (Content Mining)

- **Tujuan:** Dokumen atau gambar yang sebelumnya belum pernah dilihat harus dikategorikan ke dalam kelas dengan seakurat mungkin.
- Aplikasi
 - Kategorisasi berita
 - Kategorisasi produk
 - **Deteksi spam**
- Metode klasifikasi : Naive Bayes, Support Vector Machines), Jaringan Saraf Tiruean (Mendalam) (Deep Neural Nets), Transformers

Pengelompokan Konten (Content Clustering)

- Diberikan himpunan dokumen dan ukuran kesamaan antar dokumen, cari kelompok (cluster) sehingga:
 - Dokumen dalam satu kelompok lebih mirip satu sama lain
 - Dokumen dalam kelompok yang berbeda kurang mirip satu sama lain
- Aplikasi
 - Pengelompokan hasil pencarian (search result clustering)
 - Penemuan topik (topic discovery)
- Teknik yang Digunakan
 - Algoritma: K-Means, Pengelompokan Hierarkis (Hierarchical Clustering), S-BERT
 - Ukuran kesamaan (Similarity measures): Cosine, Jaccard, Kesamaan Embedding (Similarity of Embeddings)

Analisa Sentimen

- Tugas dasar dalam analisis sentimen adalah mengklasifikasikan polaritas teks yang diberikan pada tingkat dokumen, kalimat, atau fitur/atribut.
- Nilai Polaritas (Positif, Netral, Negatif)
- Aplikasi :
 - Prediksi suara (vote) dari tweet (contoh: pendapat publik terhadap isu politik)
 - Analisis ulasan produk (contoh: menilai apakah pelanggan puas dengan kualitas layanan, desain, atau harga)


Ekstraksi Informasi

Tujuan: Pengambilan informasi terstruktur secara otomatis dari konten web yang tidak terstruktur atau Semi-structured dari isi web

■ Contoh

Brand	Model	Type	Memory	Screen	OS
New Samsung	Galaxy S4	GT-19505	16GB	5.0 inches	Android
Smartphone with 2-Year Sprint Contract - White Frost					

■ Kesulitan dari ekstraksi informasi yang kurang terstruktur




Web Usage Mining


Ekstraksi informasi dari data yang dihasilkan melalui kunjungan halaman web dan transaksi

- Data yang disimpan dalam log akses server, log referer, log agen, dan cookie sisi klien
- Karakteristik pengguna dan profil penggunaan
- Metadata, seperti atribut halaman, atribut konten, dan data penggunaan
- Data clickstream -> **Catatan urutan klik pengguna saat menjelajahi situs web.**
- Analisis clickstream -> **Proses menganalisis pola perilaku pengguna**

Web Usage Mining (clickstream analysis)



Proses dari Web Usage Mining



Aplikasi dari Web Usage Mining

- **Product Recommendation:** sistem atau fitur yang memprediksi dan menyarankan produk yang paling mungkin diminati oleh seorang pengguna, berdasarkan data seperti perilaku, preferensi, atau kesamaan dengan pengguna lain.
- **Personalized Search (Pencarian yang Dipersonalisasi):** pendekatan dalam pencarian informasi di mana hasil pencarian disesuaikan dengan preferensi, perilaku, dan konteks pengguna individu.

Penambangan Struktur Web (Web Structure Mining)

Penemuan dan interpretasi pola dalam:

- Struktur tautan (hyperlink) di internet
- Hubungan sosial antar pelaku (aktor) yang berinteraksi di web

Sumber Graph Web

- Pencarian web (web crawls) termasuk halaman HTML dan tautan (hyperlinks)
- Jaringan sosial yang mencakup hubungan eksplisit antar pengguna (*contoh: jaringan teman di Facebook*)
- Jenis data komunitas lainnya (*forum diskusi, percakapan email, dll.*)

Aplikasi Web Struktur Mining

- Grafik Web (Web Graph): Representasi visual dari halaman web sebagai simpul (node) dan hyperlink sebagai sisi (edge).
- Analisis struktur web digunakan untuk:
 - Menentukan otoritas halaman (seperti PageRank)
 - Mendeteksi komunitas online
 - Menganalisis jaringan sosial digital


Identifikasi Simpul Penting

Pertanyaan : Siapa aktor penting dalam jaringan sosial



Centrality

- Mencari halaman penting (seperti situs berita utama)
- Mengidentifikasi pengguna influencer di media sosial
- Mendeteksi sumber informasi terpercaya




Implementasi

- Google Search: Menggunakan PageRank untuk menentukan urutan hasil pencarian.
- Twitter/Instagram: Menampilkan akun influencer pada rekomendasi.
- Analisis Jaringan Sosial: Mencari pemimpin komunitas atau penyebar berita palsu.


Deteksi Komunitas

Sebuah komunitas adalah himpunan aktor di antara mereka terjadi interaksi yang (relatif) sering.


- Menemukan komunitas dalam jaringan sosial berarti mengidentifikasi himpunan simpul (node) yang berinteraksi satu sama lain lebih sering dibandingkan dengan simpul-simpul di luar kelompok tersebut.



- Metode: Components, K-Cores
- Aplikasi : Rekomendasi system berbasis komunitas, visualisasi jaringan



Web Mining Kumpulan beberapa bidang ilmu




■ Subbidang

1. Web Usage Mining
2. Web Structure Mining
3. Web Content Mining

Proses Web Mining

Sama dengan proses data mining yang berbeda adalah tahapan pengumpulan data dan pemrosesan data





Gathering and Exploration

1. Pengumpulan data Web

- Crawling dokumen atau data
- Pengambilan data menggunakan Web API

2. Ekplorasi data

- Memahami data
- Ringkasan statistic data web
- Visualisasasi data



Preprocessing and Transformation

- **Mentransformasi data ke dalam representasi data yang sesuai dengan metode data mining**
 - Reduksi dimensi
 - Seleksi fitur
 - Diskritisasi dan binarisasi
 - Transformasi atribut / teks ke vektor/ embedding
 - Mengintegrasikan berbagai sumber data
- **Pemrosesan data butuh waktu 70-80% dari proyek data mining**
- **Mempersiapkan data dengan baik akan menghasilkan model yang layak dan valid**

Actual Data Mining


- Input: Preprocessed Data

- Output: **Model / pola**

1. Menggunakan metode data mining
2. Mengevaluasi resulting model / pola

3. Iterasi

- Ekperimen dengan menetapkan berbeda beda hyperparameter
- Ekperimen dengan beberapa metode lain
- Memperbaiki praproses data dan pembangkitan fitur
- Meningkatkan jumlah dan kualitas data pelatihan



Penambangan teks (Text Mining)

- Penambangan teks (Text mining) (text data mining)
 - Proses mendapatkan informasi yang berkualitas dari teks
- Macam macam tugas text mining
 - text categorization/classification
 - text clustering
 - concept/entity extraction/ topic modelling
 - sentiment analysis
 - document summarization